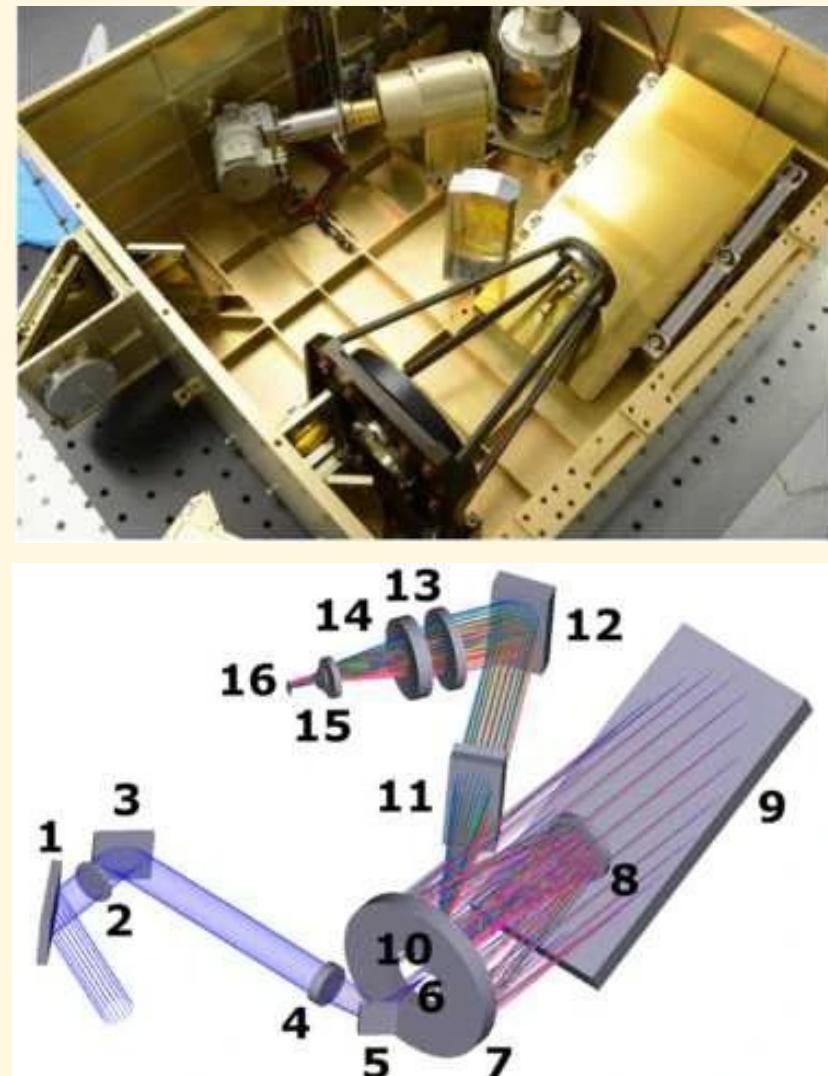
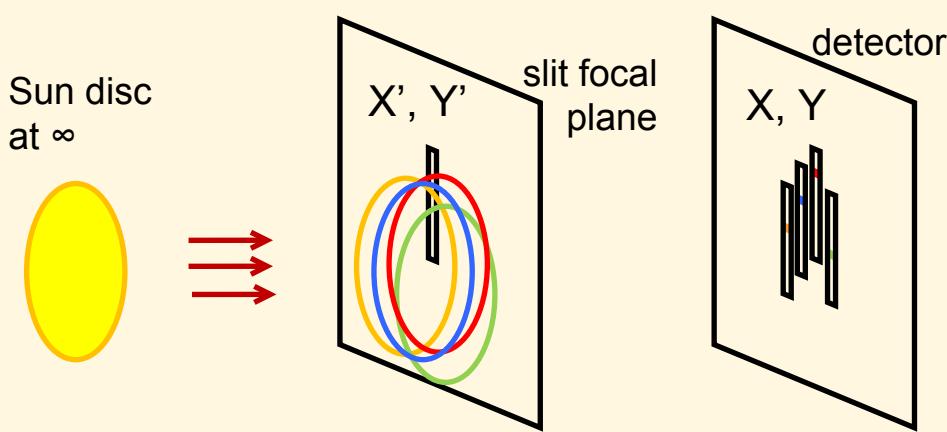


The ACS MIR instrument on TGO

ACS (2018-today) is comprised of three infrared spectrometers onboard the TGO spacecraft orbiting Mars, dedicated to the observation of Mars atmosphere. The high resolution middle infrared channel (MIR), with a potential spectral resolution of 1/50000, has the main task of picking up faint narrow spectral absorption lines from trace gases.

The MIR spectrometer optics was damaged after launch, the precise failure mechanism being still debated. It appears that multiple images of the sun disc from on the focal plane of the detector, each one with a slightly different field of view and optical path (hence geometrical corrections).

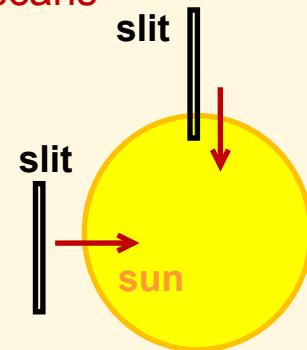
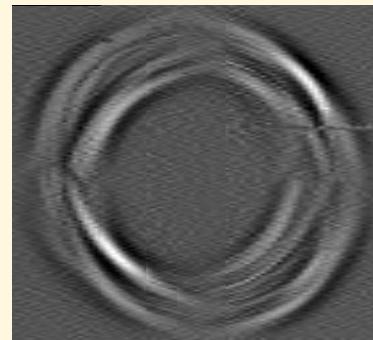


Solving the inverse problem

By performing special parametric Sun scans observations, cleverly combining time-wise derivatives, data segmentation and integration, it is possible to isolate one by one the replica images.

This technique is not applicable for normal science observations, and the parameters of the model are drifting both on long and short timescales.

differential solar scans



Could a physics-inspired machine learning approach perform MIR instrument model inversion better than a classic deterministic iterative inversion scheme?



Apprentissage par transfert pour la sélection génomique de variétés adaptées aux scénarios de la transition agro-écologique

François VICTOR
MIA Paris-Saclay
INRAE - AgroParisTech

ECAS 2025 – Towards Reliable Machine Learning

Contexte

Objectif : Prédiction des performances des variétés européennes dans différents environnements cibles.

- Développement et sélection des cultures adaptées aux scénarios de la transition agro-écologique.

Défis liés aux données

- Peu de données **européennes** (variétés et environnements qui m'intéressent)
- Données **américaines** massives mais plan d'expérience très incomplet.
- Développement d'une méthode d'apprentissage par transfert qui passe à l'échelle

Modèle de prédiction génomique

$$Y_{ge} = \mu_e + \alpha_g + U_{ge} + E_{ge}$$

$$U \sim \mathcal{N}(0, \Omega_G \otimes K)$$

$$K = \frac{XX^\top}{\text{trace}(XX^\top)}$$

$$E_{ver} \sim \mathcal{N}(0, \sigma_E^2)$$

Y_{ver} : rendement en T/hectare

α_g : e et fixe du génotype g

μ_e : e et fixe de l'environnement e

U_{ge} : e et aléatoire G × E

Ω_G : covariance génétique

K : matrice de relation génomique

X : matrice des marqueurs (SNP)

E_{ver} : erreur du modèle

- quantifier le G × E
- $\approx 10^5$ observations, nécessité de passer à l'échelle en coût de calcul
- plan d'expérience très incomplet :

$$\frac{\#\{(g, e) : Y_{ge} \text{ observé}\}}{|\mathcal{G}| \cdot |\mathcal{E}|} \ll 1$$

→ Régularisation par les marqueurs génétiques :
L'information pour chaque paire $(g, e) \in \mathcal{G} \times \mathcal{E}$ est partagée au niveau du génome.

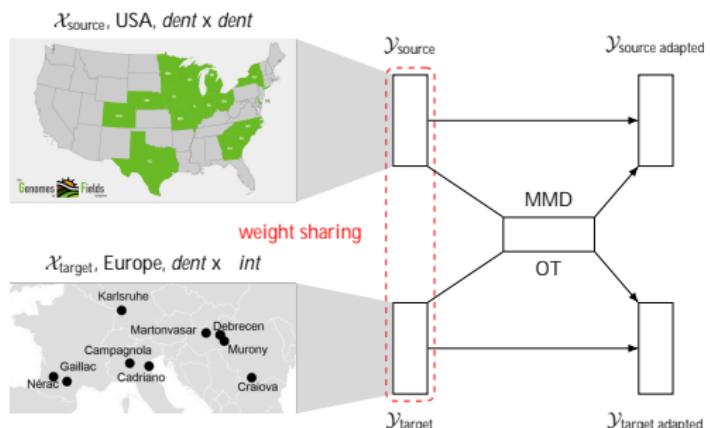
Adaptation de domaine supervisée

$$X = \{\text{SNP, cov. environnement}\}$$

Grand jdd américain (source) :
 $\mathcal{D}_s = \{(x_i^{(s)}, y_i^{(s)})\}_{i=1}^{n_s}, n_s \approx 10^5$

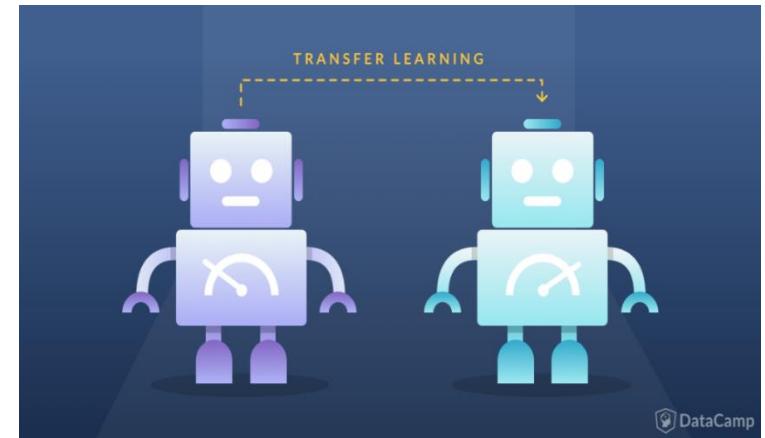
Petit jdd européen (cible) :
 $\mathcal{D}_t = \{(x_j^{(t)}, y_j^{(t)})\}_{j=1}^{n_t}, n_t \approx 10^3$

Objectif : minimiser le risque cible
 $\min_{\theta} \mathcal{R}_t = \mathbb{E}_{(x,y) \sim P_t} [\ell(\hat{y}, y)]$



Youba ABED

- Thèse en mathématiques appliquées : collaboration entre IFP Energies Nouvelles et Université Lumière Lyon 2
- Thèse intitulé « **Transfert de modèles cinétiques d'hydroprocessing de charges fossiles à des charges NTE par transfer learning** »



Julien JACQUES

Professeur des universités en Mathématiques Appliquées (Université Lyon 2)

Victor COSTA

Ingénieur de Recherche, Direction Expérimentation Procédés

Benoit CELSE

Ingénieur de Recherche, Direction Conception Modélisation Procédés

Denis Guillaume

Ingénieur de Recherche, Direction Sciences et Technologies du Numérique

Directeur de la thèse

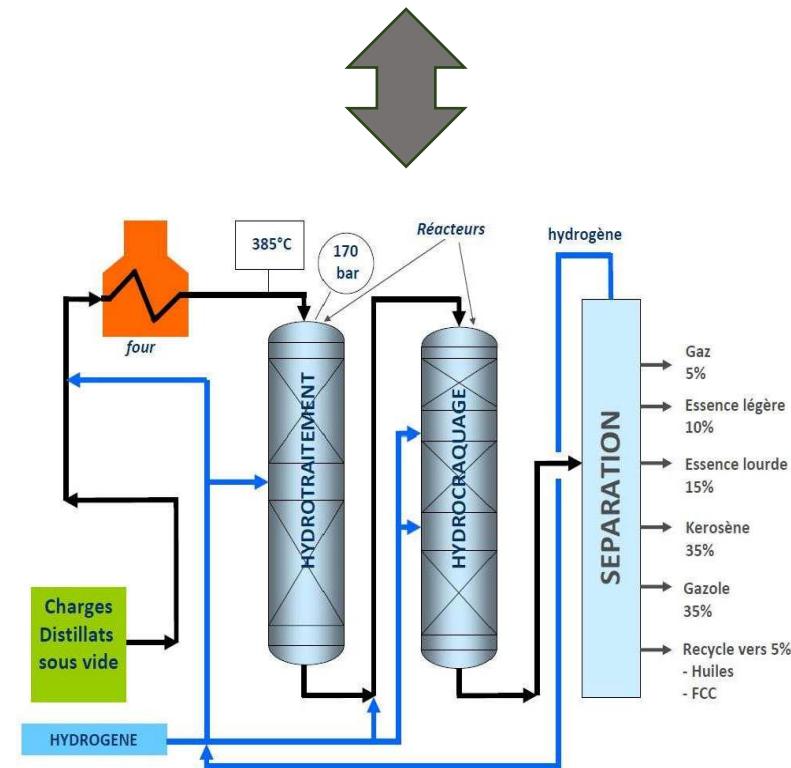
Promoteur IFPEN

Co-promoteur IFPEN

Co-promoteur IFPEN

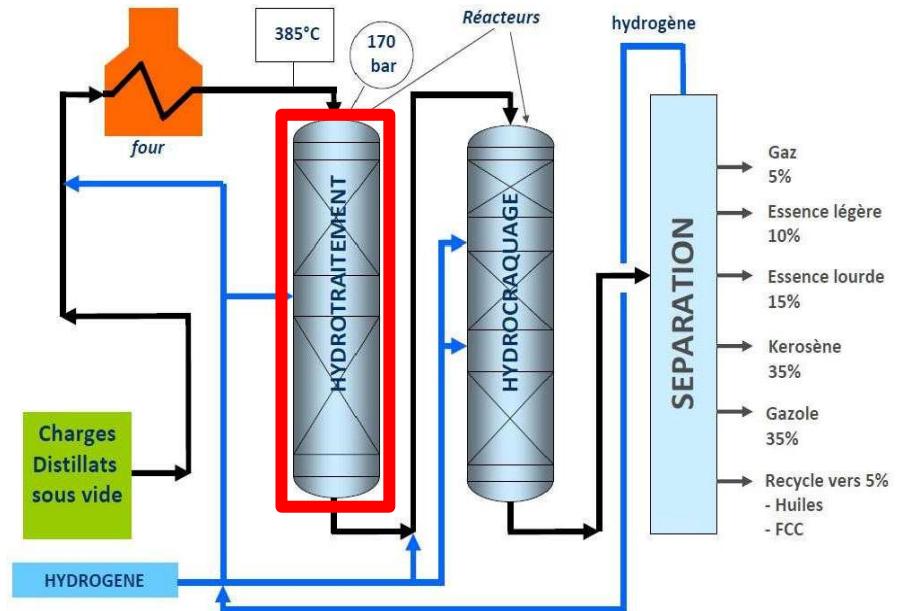
Contexte

- En raffinerie, les charges de type distillat sous vide (DSV) sont transformées en gazole dans des unités d'hydrocraquage
 - Opération sous haute pression d'H₂, haute T et en présence de catalyseurs
 - Deux sections réactionnelles
 - L'hydrotraitement purifie les charges en éliminant des impuretés tels que N et S
 - L'hydrocraquage transforme les charges purifiées en produits de valeurs
- Le groupe IFPEN commercialise des catalyseurs et des unités d'hydrocraquage
 - Historiquement, les charges étudiées proviennent du pétrole
 - Récemment, intégration des charges renouvelables (NTE) [co-processing]



Contexte

- Modélisation de la section d'hydrotraitemet
 - Concentration de l'azote dans l'effluent HDT critique [cible ~ 10 ppm]
 - Modèle cinétique pour l'HDN (hydrodeazotation) : EDO
 - EDO dépend de features et de paramètres
- Avantages
 - Meilleure connaissance des phénomènes physico-chimiques
 - Design de nouvelles installations
 - Elaboration de scenarios
- Inconvénients
 - L'optimisation des paramètres de l'EDO nécessitent beaucoup de données
 - Chaque 2-3 ans, un nouveau catalyseur ⇒ nouveau modèle



○ Solution : Transfer Learning

- Transférer les connaissances d'un ancien catalyseur (**source**) vers le nouveau catalyseur (**target**)

Objectifs

● Objectifs de la thèse

- Transfer learning du domaine fossile (source) vers le domaine NTE (target)
 - Source (fossile) = (X_S, y_S) , target (NTE) = (X_T, y_T)
 - $X_S = (X_1, \dots, X_n) \subset X_T = (X_1, \dots, X_n, \dots, X_m)$
 - ⇒ **Apprentissage par transfert hétérogène (HTL pour heterogeneous transfer learning)**
- Structure de l'EDO du catalyseur du « fossile » est connue
- Deux scénarios étudiés
 - Structure de l'EDO du NTE **connue**
 - Structure de l'EDO du NTE **inconnue**

Notation : S - source, T - target

Automated methods for building models in pharmacokinetic studies using a population approach

Matthias PIERRE^{1,2}

Supervised by Dr. Julie BERTRAND¹ and Frano MIHALJEVIC²

¹Université Paris Cité and Université Paris Sorbonne Paris Nord, Inserm, IAME, F-75018 Paris, France

²Simulation Plus, PTO

10/02/2025



Université
Paris Cité

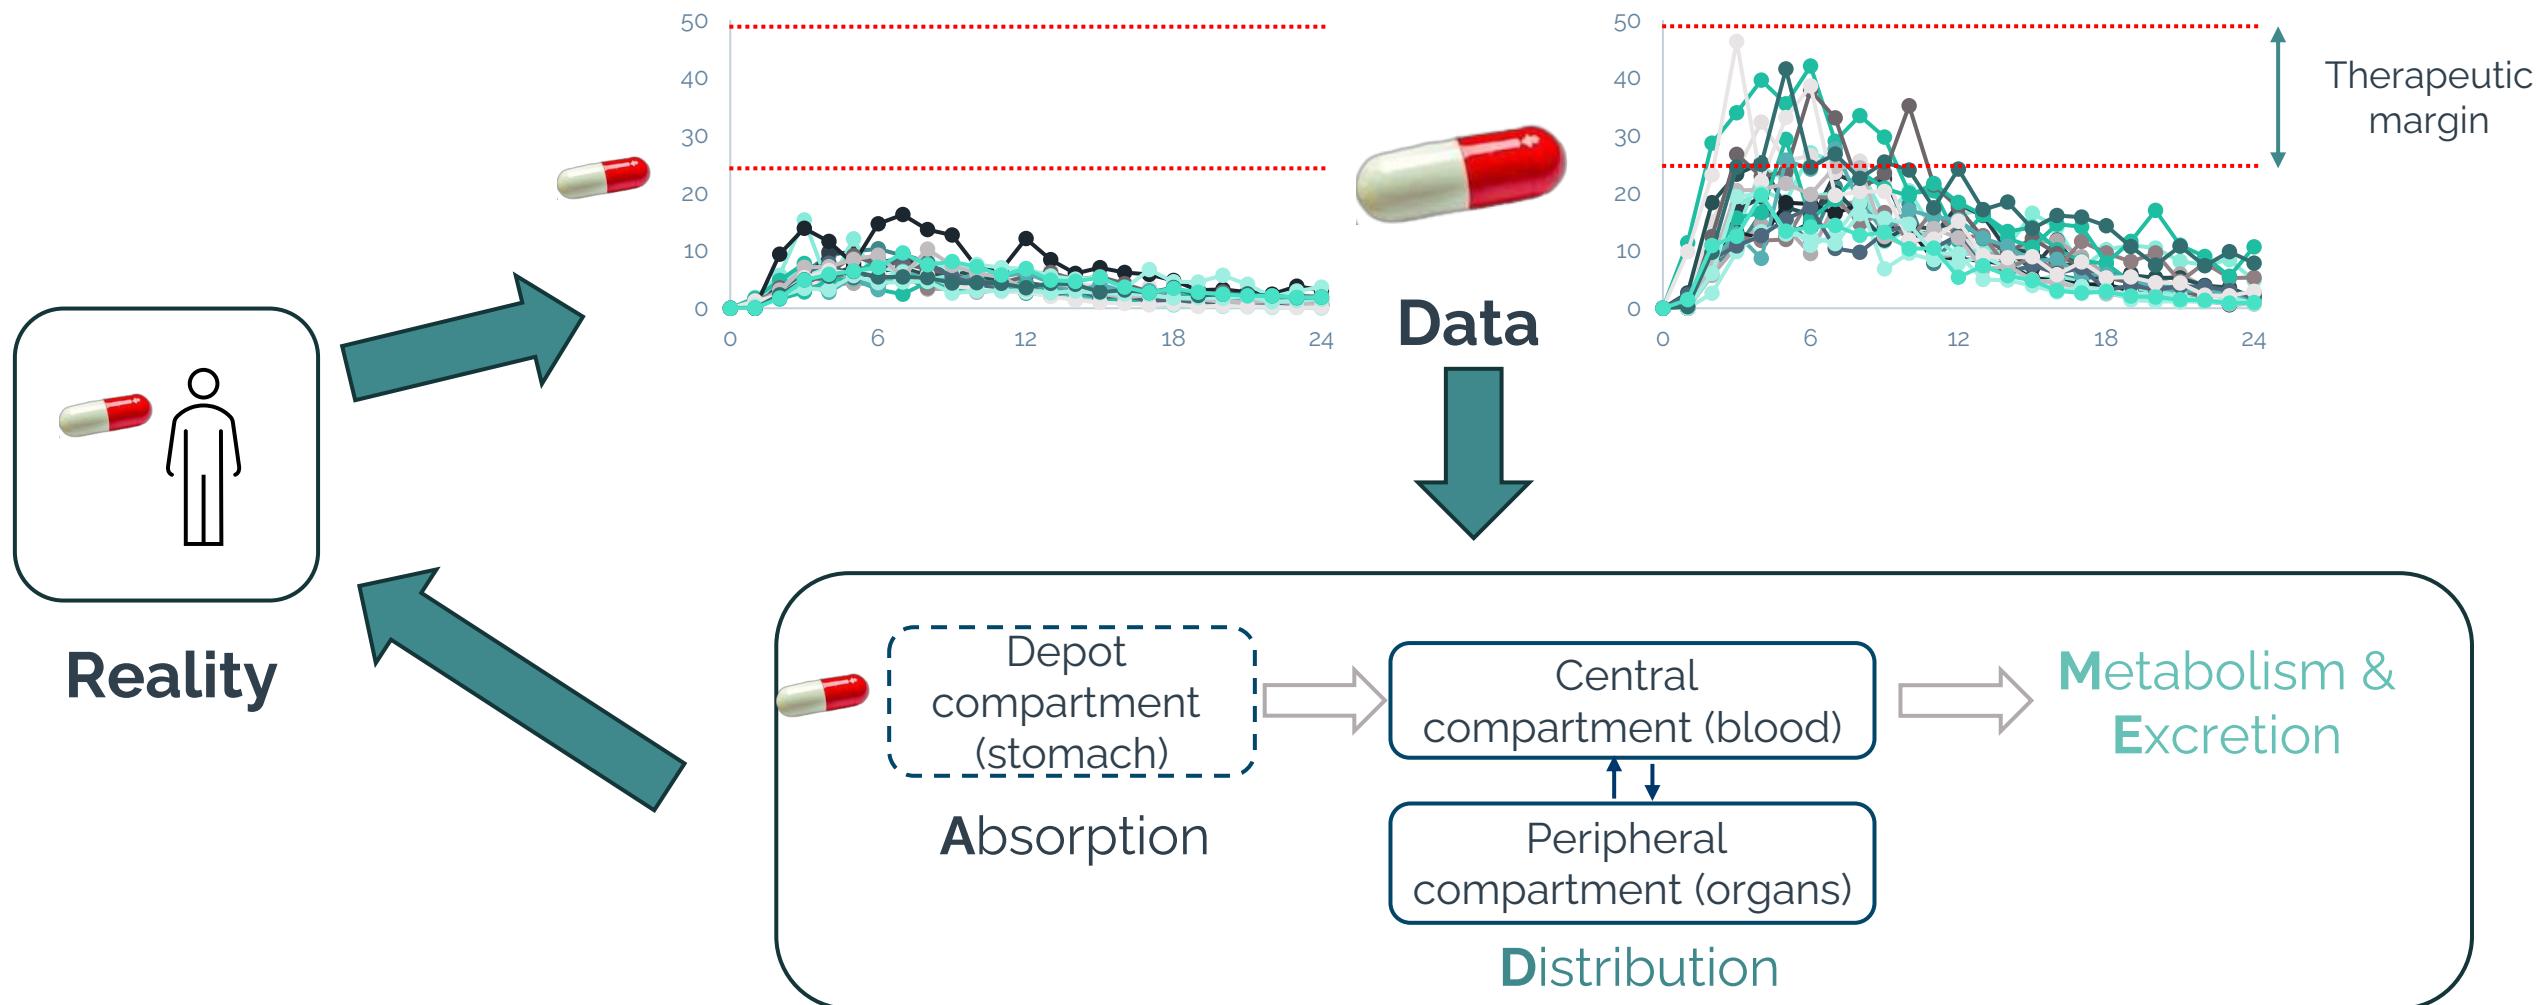


SimulationsPlus

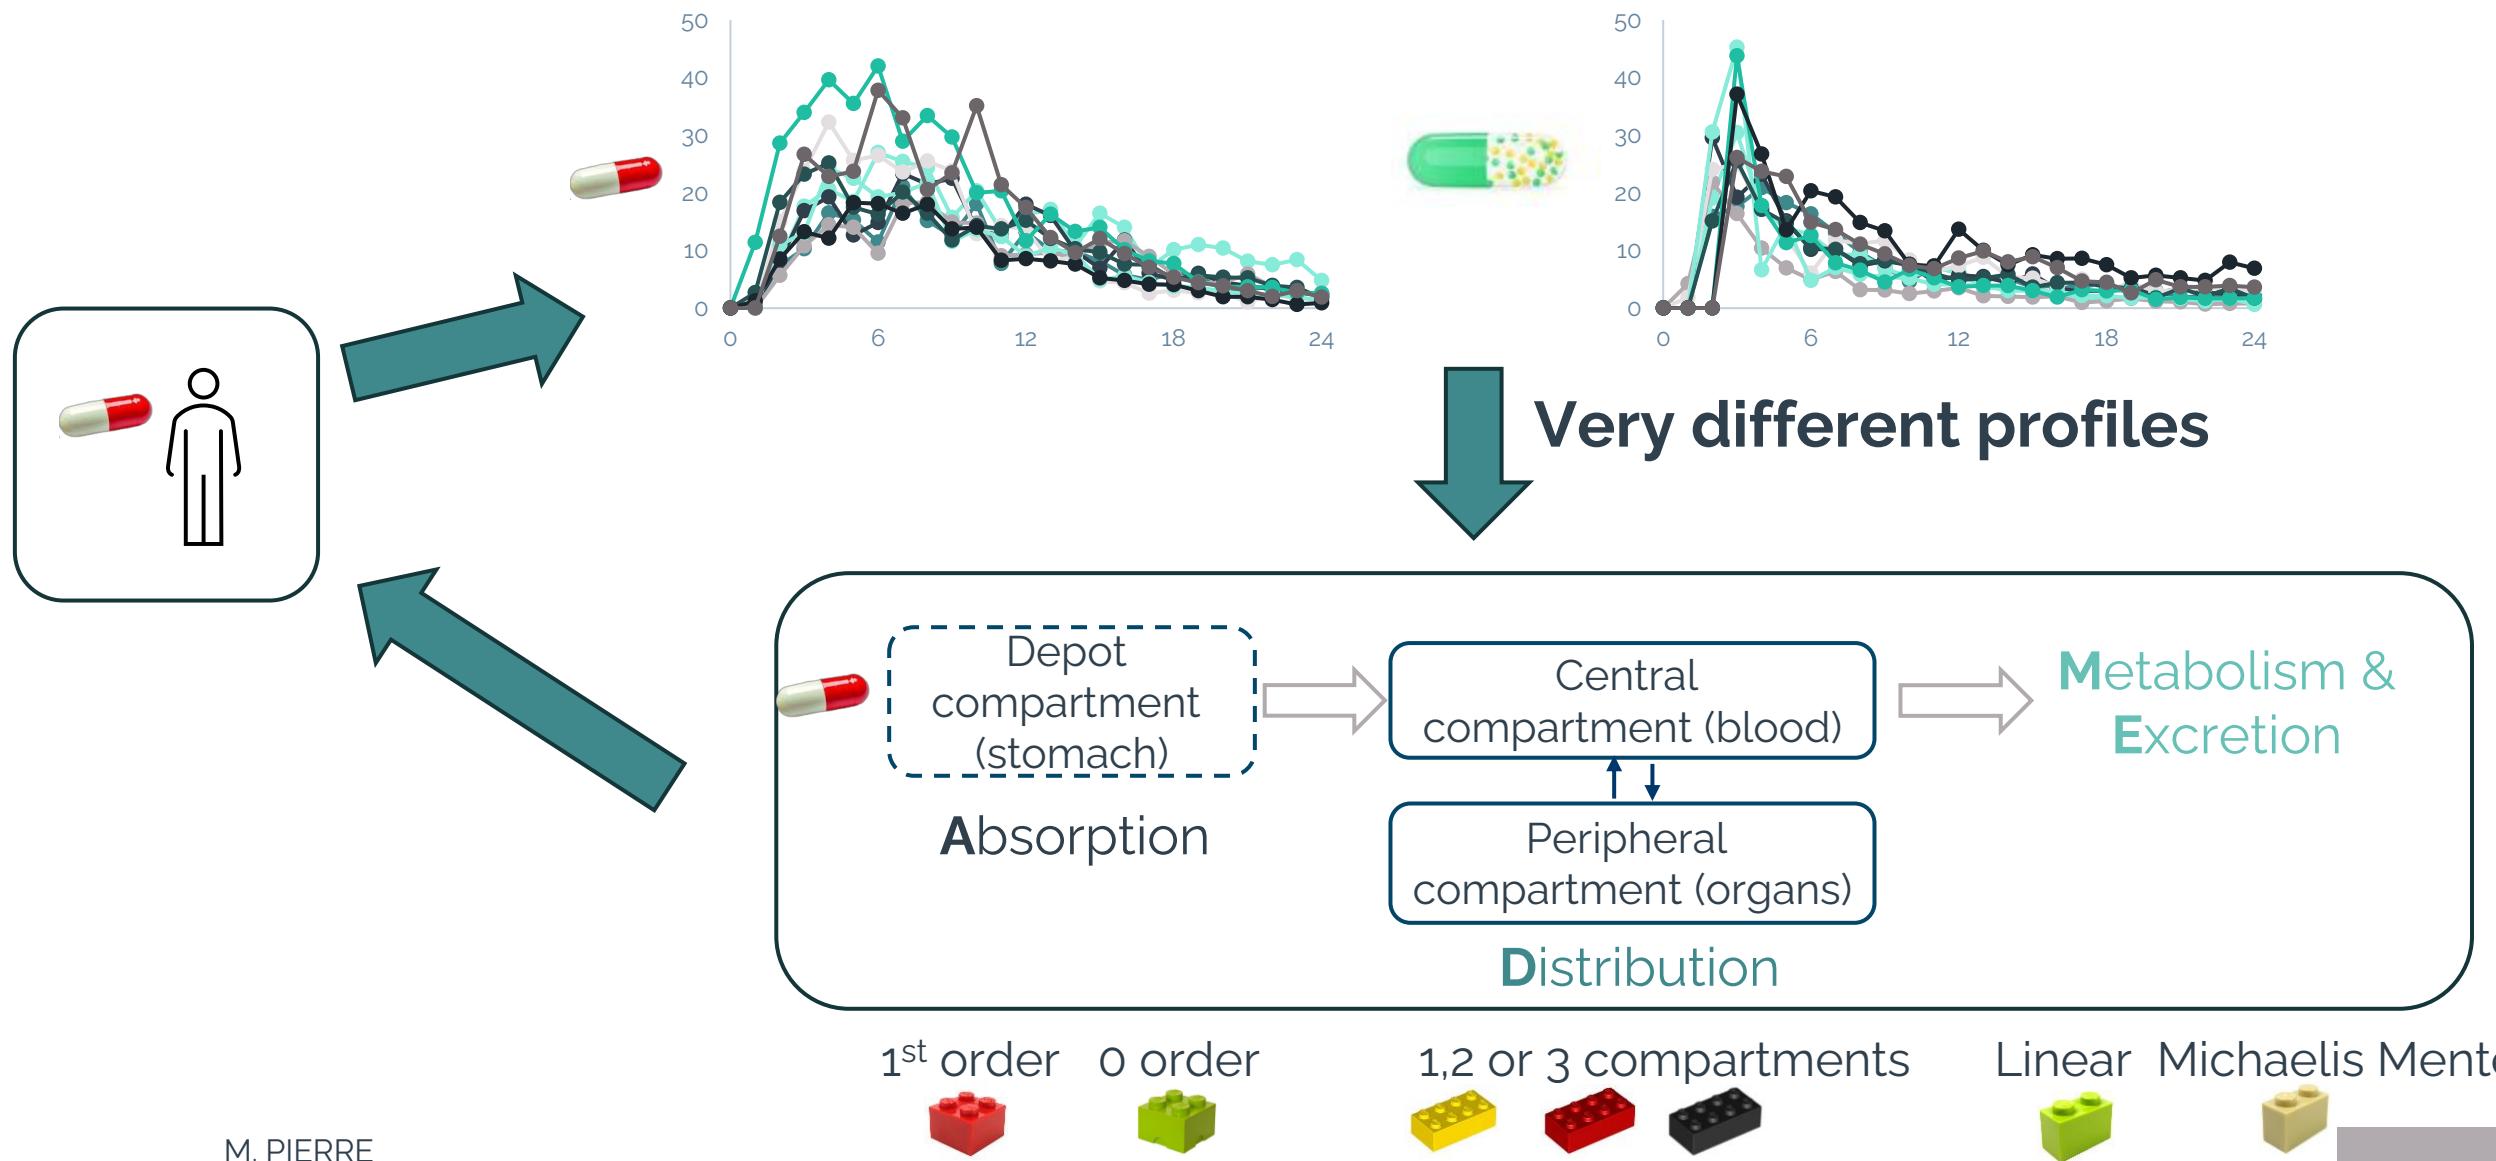
Background

- 2023: Master of engineering at CentraleSupélec
- 2024: Worked on Design evaluation in clinical trial
- 2024: PhD in Model Selection in pharmacokinetic

Motivation



Motivation

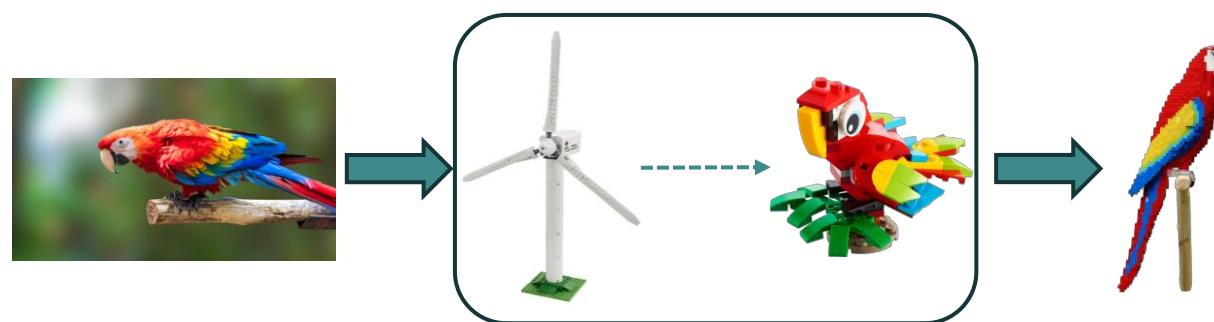


What is done now ?

- Create a model piece by piece, by hand, with the general knowledge of the drug, the dataset and his expertise
- Several modelers can find different model based on the same data
- Take lots of time

Possible solutions

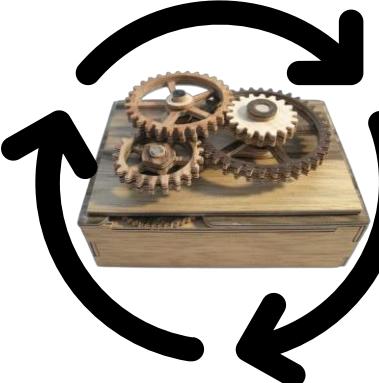
Optimization algorithm



Create a model by testing different combination of pieces and as we go along converge to the best model

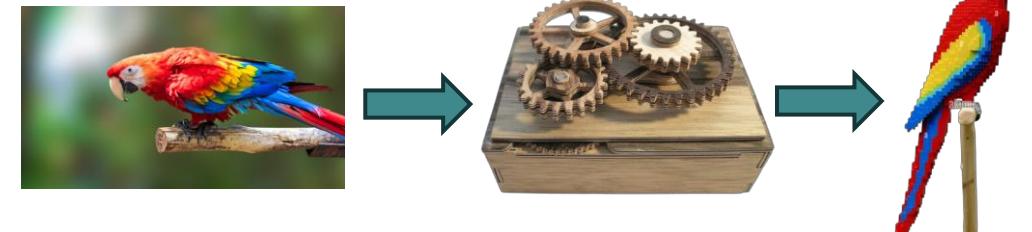


Training



Machine learning algorithm

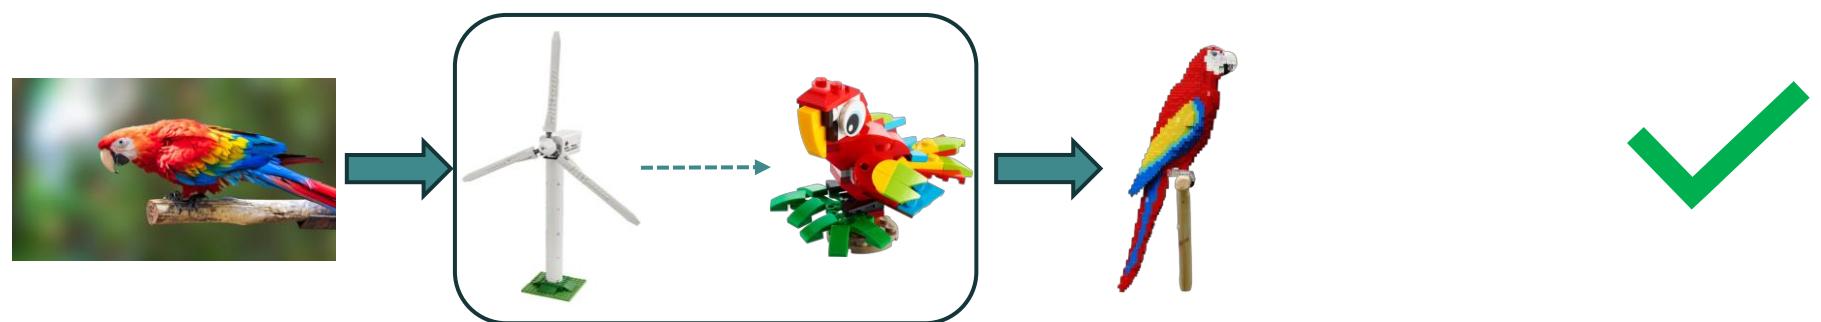
Then



Train an algorithm with all the possible model and then based on its knowledge it will return the best model for a dataset

Possible solutions

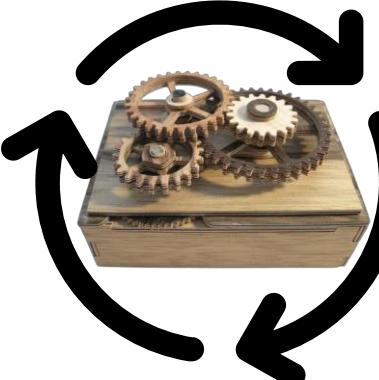
Optimization algorithm



Create a model by testing different combination of pieces and as we go along converge to the best model

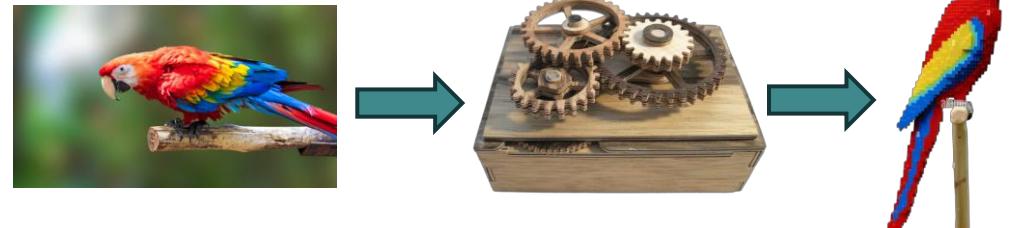


Training



Machine learning algorithm

Then



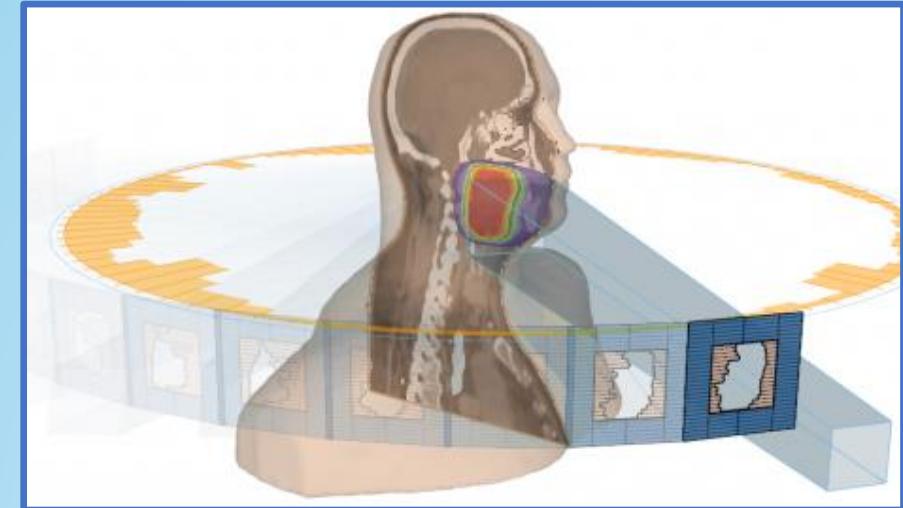
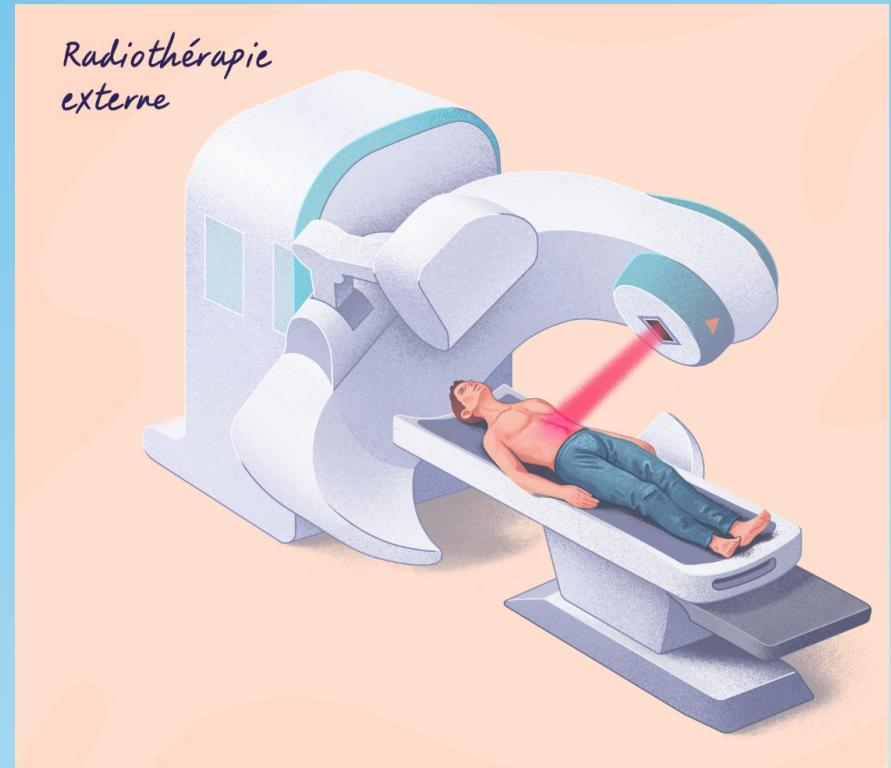
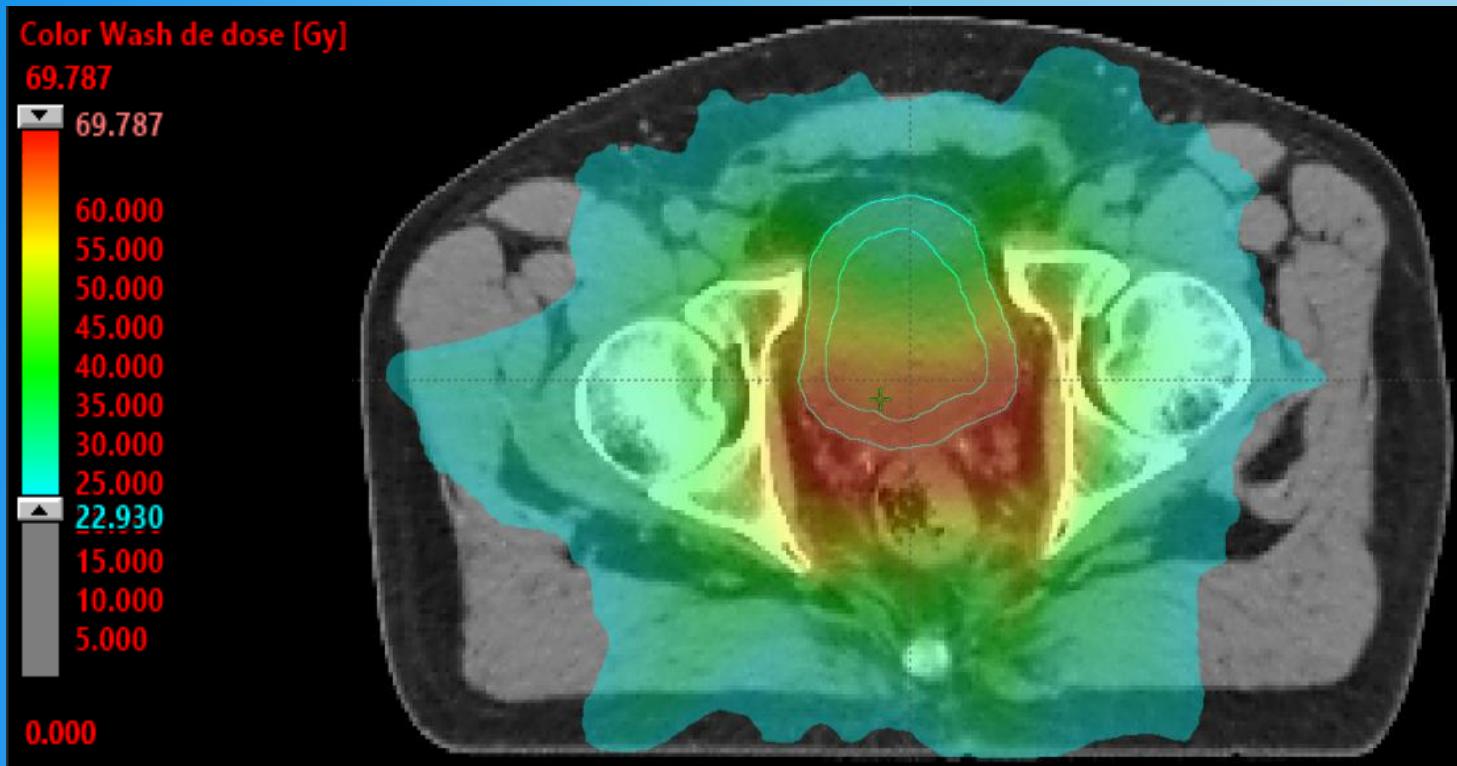
Train an algorithm with all the possible model and then based on its knowledge it will return the best model for a dataset

Thank you for your attention

Radiotherapie (RT)

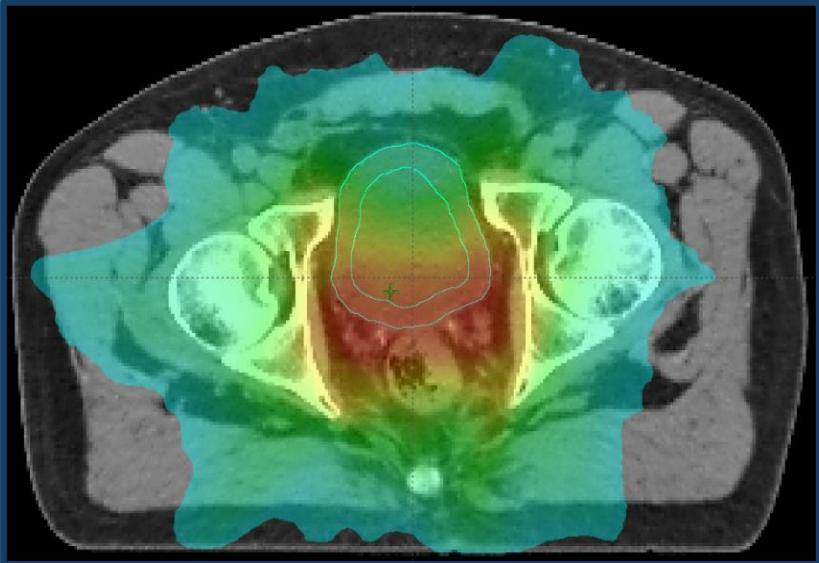
X-ray → tumor volume

Dose in gray (Gy : J.kg⁻¹) damage DNA
⇒ Cells death



Technical datas

Physicians
+
Dosimetrists



Model A

Technical datas
structured

Clinical datas structured

Radio-
therapists

Aperçu questionnaire	
Titre	1ère CS SEIN
Type	Clinique
DIABETE	
Oui	Non
TABAC	
Oui	Non
NOMBRE DE PAQUET-ANNEE	
PRECISION TABAC	

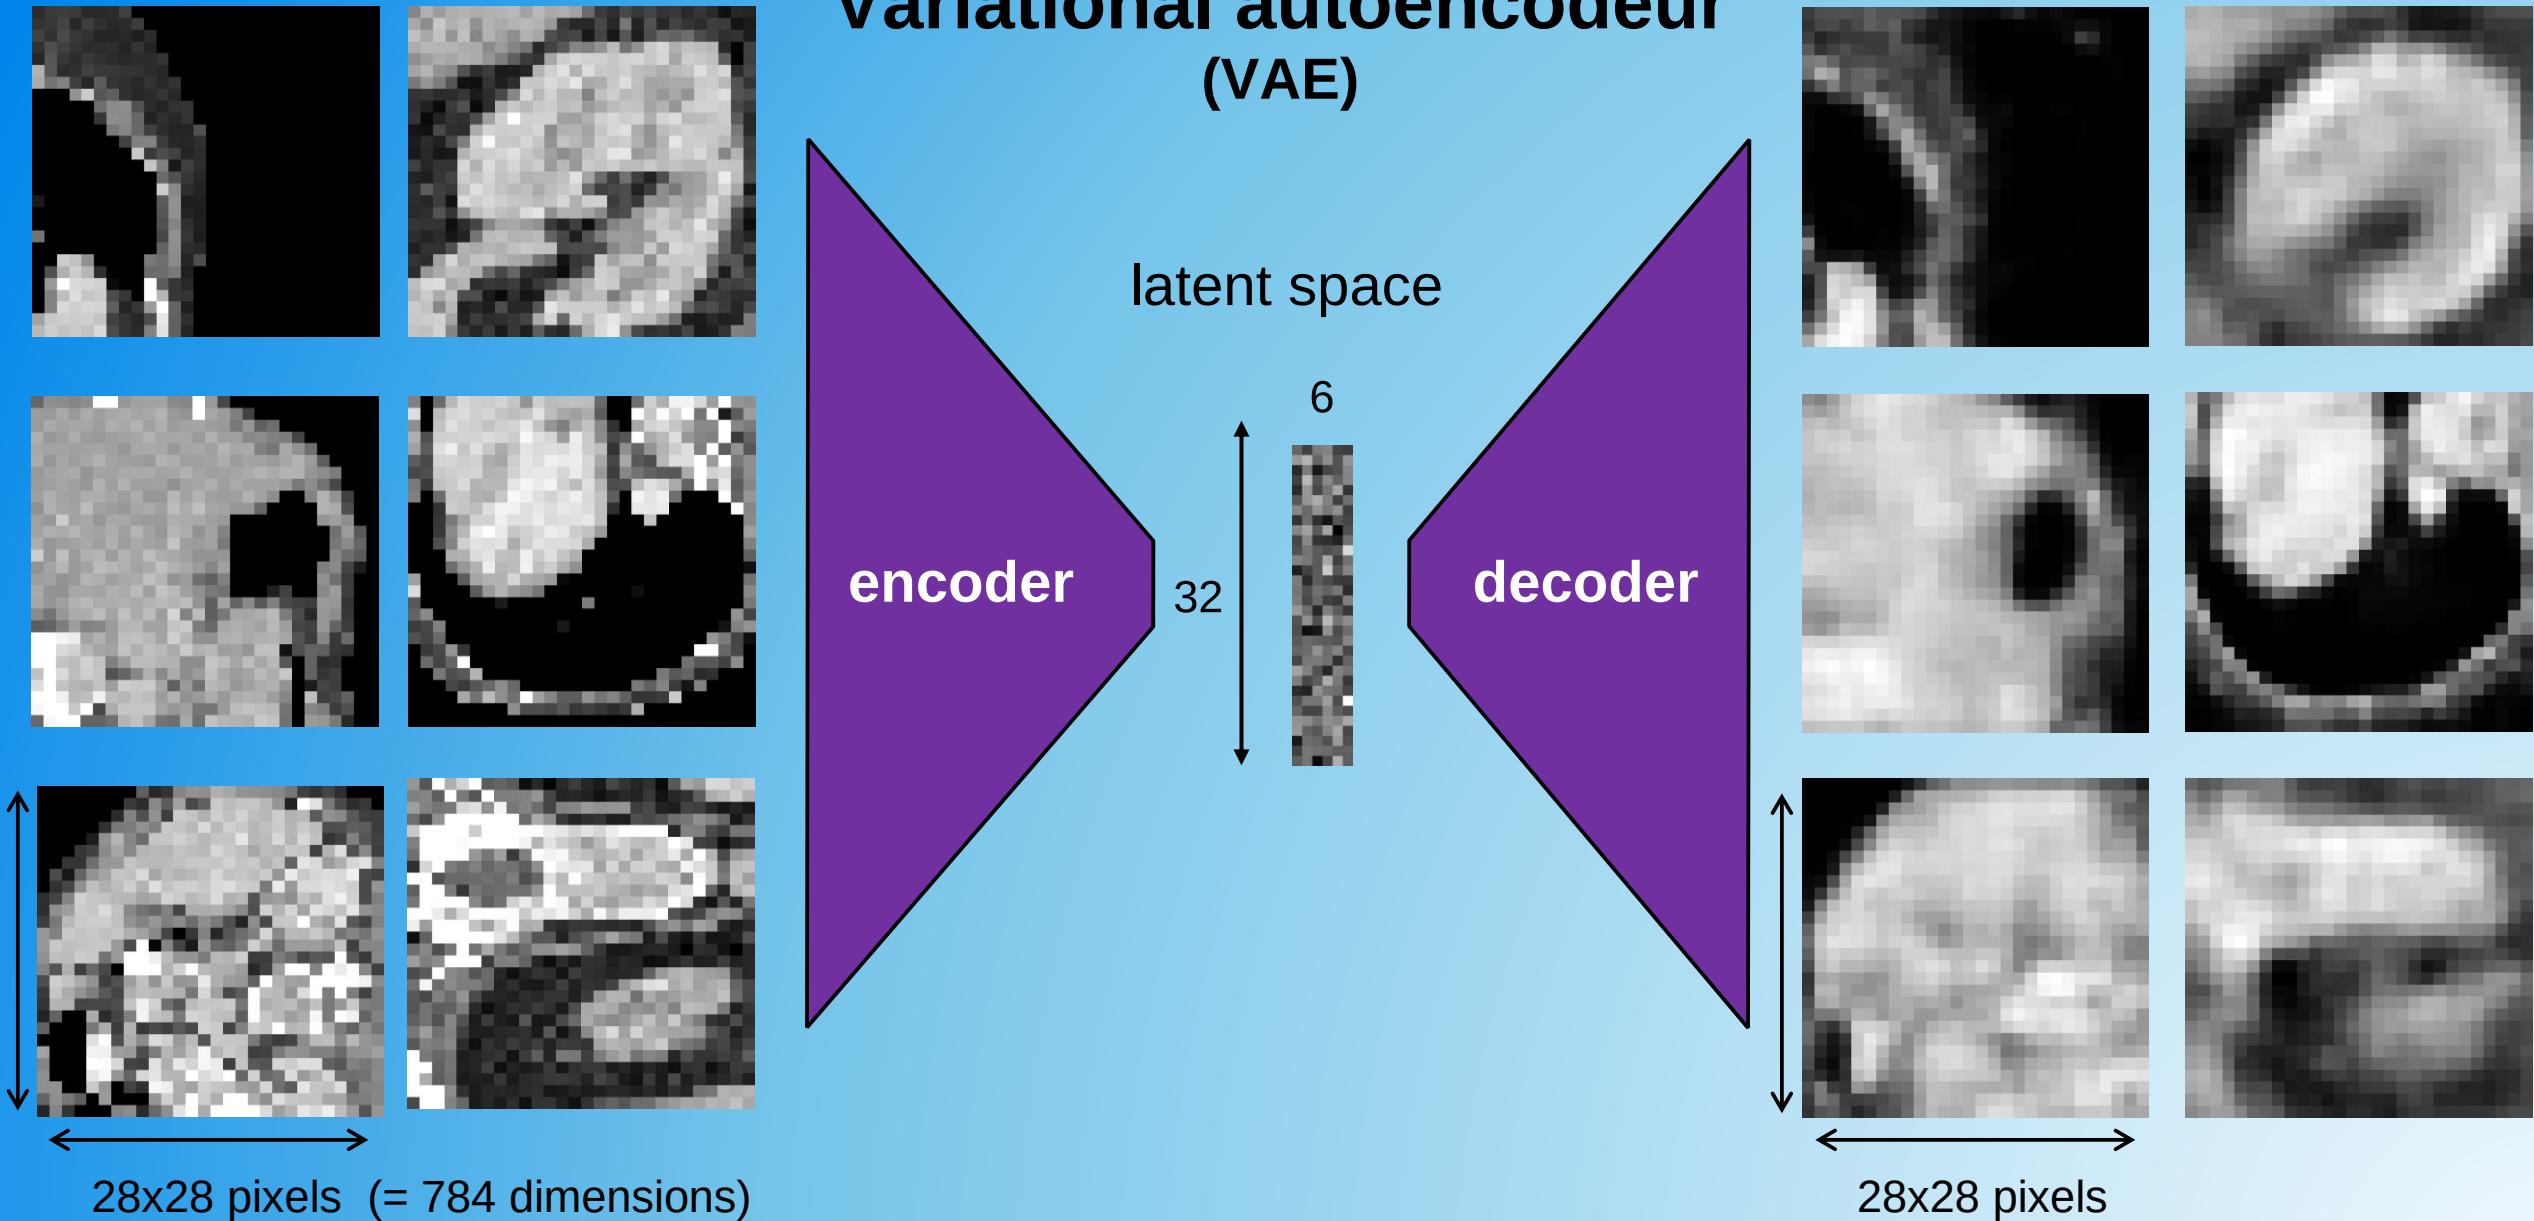
Aperçu questionnaire					
Titre	TOXICITES SEIN				
Type	Clinique				
DERMITE RADIQUE					
G0	G1	G2	G3	G4	G5
OEDEME LOCALISE					
G0	G1	G2	G3	G4	G5
PRURIT					
G0	G1	G2	G3	G4	G5
DOULEUR MAMMAIRE					
G0	G1	G2	G3	G4	G5

Model C

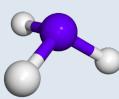
Toxicities
explanation
according
patient profil
and specific
treatment

Model A

Variational autoencodeur (VAE)



Prédiction des émissions d'ammoniac post fertilisation en utilisant des méthodes de Machine Learning



Armand Favrot – David Makowski, Sophie Génermont, Céline Decuq, Vincent Guigue

- L'ammoniac est un précurseur des particules fines (PM2.5, PM10)

Le Monde

Consulter le journal

Actualités ▾ Économie ▾ Vidéos ▾ Débats ▾ Culture ▾ Le Goût du Monde

En Ile-de-France, une pollution inquiétante mais pas exceptionnelle

La concentration en particules fines s'établit à des niveaux élevés ces derniers jours, et a déjà dépassé quatre fois le seuil d'alerte en 2015, ce qui rejoint la tendance de 2014.

- Impact négatif sur l'environnement (e.g. acidification des sols)
- Proviens à 94 % de l'agriculture, en particulier de la fertilisation des champs
- Besoin de modèles pour : tester des scénarios de réduction, inventaires, ...

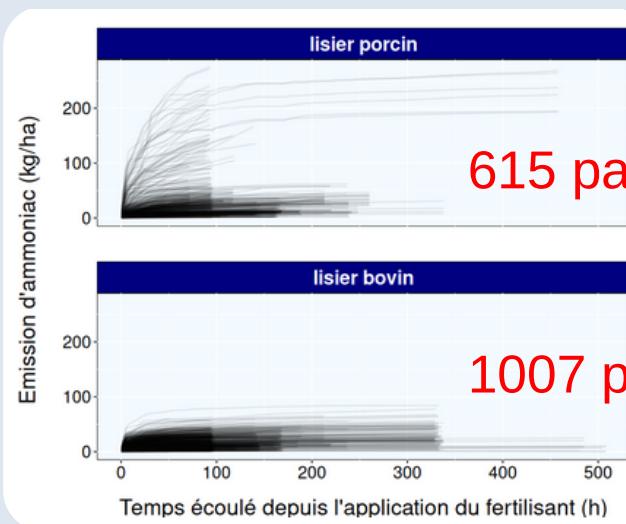
Données disponibles : 2 types de données



Données terrain

Lisier porcin

Lisier bovin



Données labo

Lisier porcin

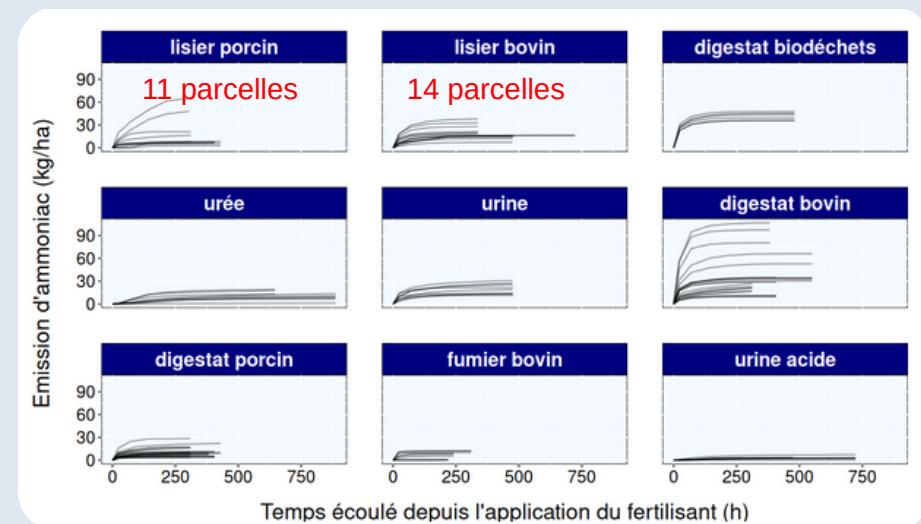
Lisier bovin

Digestat biodéchets

Urée

Urine

⋮



- Exemples de covariables : température, vent, pluie, quantité de fertilisant, pH, type de sol, ...
- **Ce qu'on a :** un bon modèle pour lisier porcin et bovin **en conditions terrain** (RNN)
- **Objectif :** être capable de prédire pour les fertilisants de la BDD labo **en conditions terrain**

Piste : transfer learning !

Premiers essais en cours :



Idée : si ça marche avec lisier porcin labo, ça marchera avec les autres fertilisants labo

